

基于图神经网络的几何过滤增广轮廓树

Geometric Filtered Augmented Contour Tree Using Graph Neural Network

2 相关研究与研究动机

本节按“背景—研究动机—相关研究”的顺序展开：2.1 节给出等值面、轮廓树及其亏格、欧拉示性数与连通性的学术化背景；2.2 节从“选择代表性等值面”出发引出本文方法；2.3 节梳理已有的拓扑与几何两类工作。

2.1 背景

等值面 科学计算、医学影像和流体模拟中的数据常表示为定义在空间域上的标量场 $f: \Omega \rightarrow \mathbb{R}$ 。给定标量阈值 α ，其等值面 (isosurface) 定义为原像 $f^{-1}(\alpha) = \{x \in \Omega \mid f(x) = \alpha\}$ ，在三维标量场中一般是一张或多张独立的封闭曲面。Marching Cubes 等方法可在规则网格上把 $f^{-1}(\alpha)$ 显式重建为三角网格 (triangle mesh)，是流场可视化分析中刻画结构的基本工具。[1] 然而逐阈值抽取只能给出孤立层级的几何，难以揭示等值面随阈值连续变化时的全局层次结构。

轮廓树 拓扑数据分析为此提供了更紧凑的表示。轮廓树 (contour tree) 通过刻画等值面连通分量随阈值变化的演化，把连续阈值空间压缩为一棵树：它记录等值面 $f^{-1}(\alpha)$ 的连通分量随阈值 α 变化而出生、合并、分裂与消亡的过程。[5, 6] 形式上，它可由记录子水平集 $F_\alpha = \{x \in \Omega \mid f(x) \leq \alpha\}$ 连通分量演化的并树 (join tree) 与记录超水平集演化的分裂树 (split tree) 合并得到。极值点、鞍点和分支节点对应关键拓扑事件，树边则表示相邻事件之间的演化区间。Topology ToolKit (TTK) 等工具已将这些结构封装为可与 ParaView、VTK 衔接的工程模块，为轮廓树的计算与增广提供了标准实现。[12]

等值面的亏格与欧拉示性数 等值面的亏格 (genus) g 在拓扑学上的直观含义是一张闭合、可定向曲面上所含“把手” (handles) 或“孔洞” (holes) 的数量，是刻画其复杂程度的核心拓扑不变量： $g = 0$ 对应球面， $g = 1$ 对应环面（如甜甜圈或带一个把手的杯子）， $g = 2$ 对应双环面， $g = n$ 则对应带 n 个相互独立把手的曲面。亏格亦可由 Betti 数刻画——对一张连通闭合可定向曲面，0 维 Betti 数 $\beta_0 = 1$ 计连通分量、1 维 Betti 数满足 $\beta_1 = 2g$ 、2 维 Betti 数

$\beta_2 = 1$ ——从而把“把手数”与曲面上独立环路的数量联系起来。[2] 对由 Marching Cubes 抽取的三角网格，亏格通过网格的点、边、面数量联合定义。对一个连通且闭合的等值面网格，其欧拉示性数 (Euler characteristic) 为

$$\chi = V - E + F, \quad (1)$$

其中 V, E, F 分别为顶点、边、三角面片总数。由拓扑学定理，欧拉示性数与亏格满足线性关系

$$\chi = 2 - 2g, \quad g = \frac{2 - \chi}{2}. \quad (2)$$

若同一阈值下抽取出 c 个彼此不相连的独立封闭曲面（各自亏格之和为 g ），则关系修正为 $\chi = 2c - 2g$ ，即 $g = (2c - \chi)/2$ 。因此，只要能沿阈值追踪 χ 的变化，就能反推等值面的亏格演化。

轮廓树与等值面亏格的关系 轮廓树本身无法完全表达等值面的亏格——它记录连通分量的演化，却不直接给出每张曲面上“把手”的数量，两个亏格截然不同的等值面在轮廓树上可能共享完全相同的边。[9] 但亏格的变化严格遵循 Morse 理论：[3, 2] 只有当阈值 h 穿过轮廓树的节点（临界点）时等值面的拓扑才会跳变，且每个临界点对欧拉示性数的贡献由其 Morse 指数 i 决定——指数 i 的临界点使 χ 改变 $(-1)^i$ 。在三维标量场中， $i = 0$ （极小值）与 $i = 3$ （极大值）对应等值面连通分量的出生与消亡， $i = 1$ 与 $i = 2$ 的鞍点则对应亏格的变化：当等值面在两处相交、在中间形成一条通道（环）时亏格加一，对应一阶鞍点 (1-saddle)；当通道闭合时亏格减一，对应二阶鞍点 (2-saddle)。据此，已有工作可在轮廓树的极小值边上初始化 χ ，沿阈值扫描在每个节点按其类型累加贡献，从而在保留树结构的同时把亏格信息补全到树的每条边上；实际数据中常出现的多重（非 Morse）鞍点需先经虚拟扰动拆解为标准一阶、二阶鞍点组合，才能保证贡献累加正确。[5, 6, 4] 本文不显式计算亏格，仅将上述关系作为说明等值面代表性、并论证“树边内部拓扑不变”的理论背景。

轮廓树与等值面连通性的关系 若说亏格描述单张曲面的复杂程度，连通性则描述等值面在阈值扫描中的整体演变，而轮廓树正是这一演变的“家谱”：它追踪并记录等值面在不同阈值下的连通分量如何诞生、合并、分裂与消失。轮廓

表 1: 三维标量场中各类临界点 (Morse 指数 i) 对等值面欧拉示性数 χ 的贡献 $\Delta\chi = (-1)^i$ 。连通分量数 c 与亏格 g 的净变化再由 $\chi = 2c - 2g$ 统一反推——同一 $\Delta\chi$ 可能来自连通性事件或亏格事件, 需结合分量数区分。

类型	$\Delta\chi$	主要拓扑含义
极小值 ($i = 0$)	+1	连通分量出生 (c 增)
一阶鞍点 ($i = 1$)	-1	连通分量合并, 或生成通道使 g 增
二阶鞍点 ($i = 2$)	+1	连通分量分裂, 或通道闭合使 g 减
极大值 ($i = 3$)	-1	连通分量消亡 (c 减)

树的节点恰是连通性发生改变的临界时刻——阈值经过极小值点时诞生一个新的连通分量, 经过极大值点时一个连通分量收缩为点而消失; 鞍点则是连通分量重组之处: 一个分量被“扯断”为两个 (分裂), 或两个原本独立的分量“黏连”为一个 (合并)。这一背景表明, 等值面的连通性与亏格变化都被编码在轮廓树的结构节点 (极值点与鞍点) 上, 而树边内部则是拓扑不变的演化区间。

2.2 研究动机

等值面是流场可视化分析中的重要工具, 选择有代表性的等值面对于刻画流场特征具有重要意义。一张等值面是否具有代表性, 可从三个方面衡量。其一是等值面的位置与分布: 代表性的等值面应覆盖标量场中不同的空间区域与阈值层级, 避免集中于单一区间而遗漏其他特征区域。其二是等值面的连通性以及亏格变化: 如 2.1 节所述, 连通分量的出生、合并、分裂、消亡以及亏格的增减都被编码在轮廓树的极值点与鞍点上, 代表性的等值面序列应完整覆盖这些拓扑事件。其三是等值面的几何特征: 即便拓扑不变, 等值面的形状、规模与截穿的局部结构仍可能明显演化, 代表性应捕捉这类几何差异。前两个方面主要与拓扑分析和简化相关, 其代表工作是轮廓树、合并树以及 Carr 等的柔性等值面框架; [6, 9, 10] 第三个方面主要与 ISM 等几何方法相关。[20] 然而如 2.3 节所述, 拓扑方法能保住连通性与亏格变化点却难以刻画分支内几何演化, 几何方法能度量形状差异却常脱离轮廓树分支、混合多分支变化, 现有研究因而并不能真正选出有代表性的等值面, 也没有方法同时针对上述三个方面。

本文正是为弥合这一空缺而提出。我们把“选择代表性等值面”具体化为增广轮廓树上的节点筛选问题: 为在连续阈值上保留代表性的等值状态, 增广轮廓树在临界节点之间插入大量普通节点, [10, 11, 13] 但相邻普通节点对应的等值结构往往高度相似, 造成冗余——保留全部普通节点会产生近似重复的等值面并增加存储与交互成本, 而不加区分地删除又会丢失真实的几何演化。本文在严格保留关键拓扑结构 (根、叶、鞍点与分支节点, 即连通性与亏格变化的临界点, 见 2.1 节) 的前提下, 沿拓扑分支筛选出

几何上有代表性的普通节点, 从而在位置分布、连通性与亏格、几何特征三个层面同时逼近原始等值面序列。

这一目标落实为三项设计。其一, 简化范围受拓扑约束: 结构节点全部保留, 候选普通节点沿所属拓扑分支顺序筛选, 简化后通过合并原始弧重建合法树, 从而保住连通性与亏格变化所依附的结构节点。其二, 基础差异度量按分支实例化: 本文统一以原始网格上的局部活性子图刻画分支局部结构, 并给出两种可替换的比较方式——活性边集合的 Jaccard 距离与活性子图的 GNN 向量化距离, 分别从显式边集与向量化结构两个角度度量几何差异。其三, 多分支场景下按重要性加权: 一个标量层级可能同时穿过主分支与旁支, 本文保留这些分支身份, 并按标量跨度型拓扑显著性与几何规模把多个分支的差异汇总为整体差异。据此, 本文提出一个拓扑保持的多分支感知增广轮廓树节点简化框架。

2.3 相关研究

围绕等值面表示与轮廓树简化的已有工作可从三个方面梳理: 拓扑驱动的合并树与轮廓树简化方法、几何驱动的等值面相似性度量方法, 以及面向网格数据的图表示学习方法。

Van Kreveld 等最早将轮廓树引入等值面遍历, 以其变体构造可证明规模最小的种子集从连通分量中精确提取等值面。[5] Carr 等提出通过合并 Join 树与 Split 树的通用维度轮廓树算法, 成为轮廓树计算的标准参考实现。[6] Edelsbrunner 等引入持久同调, 以特征在过滤中的存活时间区分信号与噪声, 奠定多尺度拓扑简化的理论基础。[7] Carr 等为轮廓树分支引入面积、体积以及兼顾空间规模与函数值偏离的超体积等局部几何度量, 作为分支剪枝的代价函数; [8] 在此基础上又提出柔性等值面框架, 以轮廓树超级弧索引独立 contour, 并结合叶子剪枝与顶点归约实现交互式简化与显示, 是本文最直接的相关工作。[9] 面向并行计算, Gueunet 等提出基于 Fibonacci 堆的任务并行增广轮廓树算法, 是本文简化工作的直接操作对象; [10] Lukasczyk 等以极值图为骨架提出 ExTreeM, 进一步降低增广合并树并行计算的串行开销。[11] Tierny 等开发 Topology ToolKit (TTK), 为合并树、轮廓树、Morse-Smale 复形等拓扑结构提供开源标准实现。[12] 在分布式与大规场景下, Li 等先将增广、超扫描与分支分解扩展到分布式环境, 使分布式轮廓树可作为科学探索的查询结构, [13] 后进一步引入预简化策略, 在数百亿网格元素上完成层次化轮廓树的构造。[14] 在合并树相似性度量方向, Sridharamurthy 与 Natarajan 提出局部树编辑距离, 把整树比较推进到子结构级; [15] Wetzels 等把 Wasserstein 测地线/重心与路径映射编辑距离结合, 得到分支分解无关的鲁棒度量; [16] Pont 与 Garth 进一步引入区域感知




图 1: 方法流程图。输入标量场与增广轮廓树, 经拓扑分支分解、多分支权重计算、分支几何差异度量, 最终通过贪心简化算法输出几何过滤增广轮廓树。

Wasserstein 距离, 把极值对齐区域的取值分布显式纳入度量。[17] 这些方法与本文均以"分支/子结构 + 几何信息"为共同切面, 但仍以手工设计的持久性/几何权重作为过滤依据, 缺少对局部几何结构本身的表达能力。

Bajaj 等提出等值面谱 (contour spectrum), 将等值面面积、体积、梯度积分等属性表达为等值的分段 B 样条函数, 首次将几何量化方法引入等值面阈值选择。[18] Chiang 与 Lu 提出保持所有可能等值面拓扑的渐进四面体网格简化算法, 是拓扑感知网格简化的关键先驱。[19] Bruckner 与 Möller 提出等值面相似性图 (ISM), 以归一化互信息比较不同阈值下的距离场结构, 从相似度矩阵中选出代表性等值面, 是等值面几何相似性度量的里程碑; [20] 但 ISM 将多个连通分支的变化混合到同一距离场描述符中, 难以区分分支级别的几何差异。Wang 提出基于区间体与等值面面积的 VOA 度量以及基于点距的分割度量, 用于自动检测代表性等值与语义化等值面分割。[21] 在此基础上, Li 等将 ISM 扩展到多视图场景, 通过跨视图一致的相似性聚类同时驱动传递函数设计与代表性等值面选择; [25] Zhou 等面向气象集合数据, 以 contour probability similarity 做非均匀下采样得到 key-isovalue, 并结合信息损失曲线自动决定采样密度。[26] 深度表征方面, Dai 等提出 IsoExplorer, 用 Octree 卷积变分自编码器学习每张连通等值面的潜表示, 把等值面相似性从"距离场互信息"迁移到"神经嵌入距离"; [22] He 等则提出 ScalarGCN, 把标量值作为图节点用 GCN 学习关联表征, 是把 GCN 系统性引入体数据分析的先驱之一。[23] Li 与 Shen 借助不确定度传播, 把隐式神经表示上的等值面提取显著加速, 代表神经场表征下的等值面几何提取方向。[24] 上述工作展示了 ISM 家族从"手工描述子"迈向"多视图/集合/神经表征"的演化, 但共同短板是脱离轮廓树的分支结构, 几何差异被混合在多分支之间。

Kipf 与 Welling 提出图卷积网络 (GCN), 通过对称归一化的一阶邻域聚合实现高效的半监督节点分类, 是图神经网络最具影响力的基石模型。[27] Hamilton 等提出 GraphSAGE, 以邻域采样与可学习聚合器实现大规模图上的归纳式表示学习, 可为新节点生成 embedding。[28] Gilmer 等提出消息传递神经网络 (MPNN) 通用框架, 将多种 GNN 变体统一到消息、更新与读出三阶段范式下。[29] Xu 等从理论上刻画消息传递 GNN 的判别能力上界, 提

出可达 Weisfeiler-Leman 测试上界的图同构网络 (GIN)。[30] 在此基础上, Rampasek 等提出 GraphGPS 通用框架, 把 GT 拆解为位置/结构编码、局部消息传递与全局注意力三部分, 实现线性复杂度的图 Transformer; [31] Bar-Shalom 等提出 Subgraphormer, 通过图积视角把子图 GNN 与 Graph Transformer 统一, 为"选取子图 + GNN 编码"这一范式提供理论表达力支撑。[32] 面向网格与曲面, Hanocka 等提出 MeshCNN, 在三角网格的边上定义卷积与池化操作, 以任务驱动的边折叠在保持拓扑的同时实现网格分辨率降低; [33] Sharp 等提出 DiffusionNet, 以基于 Laplace-Beltrami 算子的学习扩散层实现对分辨率与采样变化自动鲁棒的表面学习。[34] 面向物理仿真, Pfaff 等提出 MeshGraphNet, 以编码-处理-解码架构在非结构化网格上直接学习模拟; [35] Nabian 等进一步在图分区与多尺度图上扩展该框架, 实现工业级几何上的可扩展学习。[36] 在图度量学习方向, Jain 等提出 GRAPHEDEX, 用神经集散度学习通用代价下的图编辑距离, 代表当前"用神经网络学习图相似度"的最新水平。[37] 与本文最直接同构的工作是 Qin 等提出的合并树神经网络 (MTNN), 首次系统地用 GNN 学习整棵合并树的相似度嵌入, 将拓扑比较速度提升两个数量级。[38] 但 MTNN 学习的是"整棵合并树"的相似度嵌入用于比较任务, 而本文用 GNN 学习"分支级活性子图"的向量化用于增广轮廓树的几何过滤, 输入图结构、监督信号与下游任务均不同, 两者是"GNN + 拓扑抽象"方向的两个互补切面。

综上, 拓扑方法能保住连通性与亏格变化点却难以刻画分支内几何演化, 几何方法能度量形状差异却脱离轮廓树分支结构, 图表示学习提供了局部结构编码的工具但尚未应用于等值面代表性筛选。三者尚未在同一框架内统一, 这一空缺正是本文工作的出发点。

3 方法

本节给出基于几何过滤的增广轮廓树节点简化方法。输入为规则网格 Ω 上的标量场 $f: \Omega \rightarrow \mathbb{R}$ 及其增广轮廓树 $T = (V, E, f)$, 输出为几何过滤增广轮廓树 T' ——在严格保留连通性与亏格变化临界点的前提下, 沿拓扑分支筛选出几何上有代表性的普通节点后重建而得的简化树。图 2 给出了核心概念的直观示意: 增广轮廓树的临界点将

标量轴划分为若干亏格不变区间，每条拓扑分支对应一个区间，分支内部等值面拓扑不变、仅有几何演化。图 1 给出方法的整体流程。全文按以下逻辑展开：3.1 节定义拓扑分支与多分支权重；3.2 节说明亏格不变区间；3.3 节给出两种几何差异度量；3.4 节统一为贪心简化算法。

3.1 拓扑分支分解与多分支权重

增广轮廓树的节点按拓扑角色分为两类：结构节点集合 V_s （根、叶/极值点和分支节点/鞍点）记录连通性与亏格的变化；普通节点集合 $V_o = V \setminus V_s$ （度数为 2 的增广节点）记录中间等值面状态。从每个结构节点出发，沿度数为 2 的普通节点连续游走到下一个结构节点，即得一条**拓扑分支**（topological branch） $b_\ell = (v_0, v_1, \dots, v_k)$ ，其中 $v_0, v_k \in V_s$ 为必须保留的端点，中间节点按标量值定向排列，全为候选普通节点。整棵增广轮廓树被这些分支无重叠地分解。

每条分支 b_ℓ 的标量跨度 $\pi_\ell = f_{\max}(b_\ell) - f_{\min}(b_\ell)$ 刻画其承载的标量演化范围，可视为持久性在分支层面的近似。在轮廓树中，同一标量层级 $t_i = f(v_i)$ 可能穿过多条分支，记活跃分支集合为

$$\mathcal{B}(t_i) = \{b_\ell \mid f_{\min}(b_\ell) \leq t_i \leq f_{\max}(b_\ell)\}. \quad (3)$$

节点筛选应同时考虑所有活跃分支的变化。为此，对每条活跃分支 b_ℓ 定义两类权重：拓扑权重 w_ℓ^{topo} 按标量跨度归一化，几何规模权重 w_ℓ^{geo} 按该分支在当前层级的活性边数 s_ℓ （见 3.3 节）归一化：

$$w_\ell^{\text{topo}} = \frac{\pi_\ell}{\sum_{k: b_k \in \mathcal{B}(t_i)} \pi_k}, \quad w_\ell^{\text{geo}} = \frac{s_\ell}{\sum_{k: b_k \in \mathcal{B}(t_i)} s_k}. \quad (4)$$

二者通过混合系数 $\alpha \in [0, 1]$ 线性组合为最终权重

$$w_\ell = \frac{\alpha w_\ell^{\text{topo}} + (1 - \alpha) w_\ell^{\text{geo}}}{\sum_k [\alpha w_k^{\text{topo}} + (1 - \alpha) w_k^{\text{geo}}]}. \quad (5)$$

$\alpha = 1$ 退化为纯拓扑权重，倾向保护标量跨度大的主分支但可能低估正经历显著截交变化的旁支； $\alpha = 0$ 退化为纯几何规模权重，响应局部结构规模但可能稀释拓扑上重要的小分支。各活跃分支的局部差异 d_ℓ （定义见 3.3 节）经权重汇总为整体差异

$$D(v_r, v_i) = \sum_{\ell: b_\ell \in \mathcal{B}(t_i)} w_\ell d_\ell(v_r, v_i), \quad \sum_\ell w_\ell = 1, \quad (6)$$

其中 v_r 为最近一次保留的参考节点。 D 是贪心简化（3.4 节）的核心判据。

3.2 亏格不变区间与分支映射

Morse 理论保证：只有当阈值穿过轮廓树的临界点（结构节点）时等值面的拓扑才发生跳变，每个临界点对欧拉

示性数的贡献为 $\Delta\chi = (-1)^i$ （ i 为 Morse 指数）。因此，在两个相邻结构节点之间的标量区间内，等值面的连通分量数和亏格均保持不变。对拓扑分支 $b_\ell = (v_0, \dots, v_k)$ ，其端点 $v_0, v_k \in V_s$ 之间的开区间 $(f(v_0), f(v_k))$ 不含其他临界点，即为一个**亏格不变区间**（genus-invariant interval）。在此区间内，等值面的拓扑类型不随阈值变化，只有几何形状可能演化——这正是在分支内部做纯几何筛选的理论基础。

这一映射具有三方面关键保证：(1) 分支内部拓扑不变——任意两个普通节点的等值面具有相同的连通分量数和亏格，二者差异纯粹是几何差异；(2) 亏格变化仅发生在端点——一阶鞍点使亏格增加、二阶鞍点使其减少，本文通过保留所有结构节点来保证亏格变化点不被删除；(3) 分支间互不干涉——同一层级穿过的多条分支各自对应独立的亏格不变区间，几何比较被严格限制在各分支内部（3.3 节）。

综合以上，结构节点全部保留确保不丢失任何亏格变化事件；分支内部仅做几何筛选，不会引入或遗漏拓扑事件；多分支加权保持各分支的独立性，不跨越亏格不变区间混合比较。

3.3 分支上的几何表示学习


由 3.2 节可知，拓扑分支内部等值面的差异纯粹是几何差异。本节定义统一的局部结构描述子——活性子图，并给出两种可替换的差异度量。

3.3.1 局部活性子图

等值面在规则网格上的离散痕迹，是被其穿过的网格边。给定规则网格 Ω 上的标量场 f 和轮廓树节点 v （对应阈值 $t = f(v)$ ），若网格边 (p, q) 的两端标量值跨越阈值（即 $f(p) \leq t < f(q)$ 或反之），则称该边为阈值 t 下的**活性边**（active edge）；所有活性边及其端点构成**局部活性子图** $G_\ell(v) = (V_{\text{act}}, E_{\text{act}})$ 。直观上，活性边集合标记了等值面在网格单元中“穿过”的位置——Marching Cubes 中每条活性边上的插值点正是等值面顶点——因此活性边集合以离散、无插值的方式完整编码了等值面的空间截交结构。

相比直接重建等值面三角网格，活性子图具有三个优势：(1) 无需插值和三角化；(2) 所有阈值下的活性子图共享同一顶点编号空间，不同阈值的活性边集合可直接做集合运算（交、并）而无需额外对应关系；(3) 子图规模随等值面复杂程度自适应缩放，规模本身即携带几何信息。

为把比较限制在当前分支 b_ℓ 的亏格不变区间内，本文利用增广轮廓树已有的分割标签（SegmentationId）实现**分支局部化**：对分支 $b_\ell = (v_0, \dots, v_k)$ ，取其关联弧分割区域的联合轴对齐包围盒作为空间搜索范围，仅在此范围内



变化)。在实际数据中,三者往往不同步:例如等值面可能形状不变但平移显著,或形状骤变但质心不动。取最大值意味着任一通道发生显著变化都足以触发保留,避免了求和或均值中不同通道相互稀释的问题——一个通道的"无变化"不会拉低另一个通道的"剧变"信号。

3.3.3 局部活性子图的 GNN 向量化差异

交集 Jaccard 直接且可解释,但存在两个固有局限:其一,对网格离散化敏感——等值面仅微小偏移一个网格间距就可能导致大量活性边替换,使 Jaccard 差异偏高;其二,缺乏结构感知——Jaccard 仅统计边的交并比,无法区分"集中在同一区域的边替换"(等值面局部凹陷)与"分散在多处边替换"(等值面整体形变)。第二种度量将活性子图编码为固定长度向量后在向量空间中比较,将"边是否逐一重合"放松为"局部结构是否相似",通过消息传递机制捕获边替换的空间分布模式。

节点特征设计。 对每个活性顶点 p 构造 11 维特征向量 $x_p \in \mathbb{R}^{11}$, 由四组信息拼接而成:

- **标量信息** (3 维): 归一化标量值 $\hat{f}(p) = (f(p) - f_{\min}) / (f_{\max} - f_{\min})$, 反映顶点在全局标量范围中的位置; 相对阈值偏差 $(f(p) - t) / (f_{\max} - f_{\min})$, 刻画顶点相对于当前等值面的"远近"; 以及其绝对值 $|f(p) - t| / (f_{\max} - f_{\min})$, 消除方向信息仅保留距离量级。标量特征使 GNN 能区分等值面两侧的顶点角色 (内侧 vs. 外侧)。
- **空间坐标** (3 维): 相对质心坐标 $(p - c(v)) / \text{diag}(v)$, 按活性子图包围盒归一化。归一化消除了不同分支间的绝对位置和尺度差异, 使 GNN 关注相对空间分布。
- **拓扑连通度** (1 维): 顶点在活性子图中的度数, 归一化为 $\deg(p) / \deg_{\max}$ 。度数反映局部连通密度——高度数顶点处于等值面的密集交叉区域。
- **分割标签编码** (4 维): 将 SegmentationId 通过多尺度三角函数编码为 4 维向量 $[\sin(s/P_1), \cos(s/P_1), \sin(s/P_2), \cos(s/P_2)]$ (P_1, P_2 为预设周期)。这一编码使 GNN 在消息传递中能识别邻居顶点是否属于同一分割区域, 从而区分"分支内部边"与"分支边界边"。

图卷积编码。 以特征矩阵 $X \in \mathbb{R}^{|V_{\text{act}}| \times 11}$ 和活性子图邻接为输入, 两层图卷积网络 (GCN) 做对称归一化聚合:

$$H^{(l)} = \text{ReLU}(\hat{A} H^{(l-1)} W^{(l)}), \quad l = 1, 2, \quad (11)$$

其中 $H^{(0)} = X$, $\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ 为加自环的对称归一化邻接矩阵 ($\tilde{A} = A + I$, $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$), $W^{(l)} \in \mathbb{R}^{d_{l-1} \times d_l}$

为可训练 (或固定) 权重矩阵。两层聚合意味着每个顶点的最终表示融合了其 2-hop 邻域的信息——在规则网格中, 这覆盖了以该顶点为中心、半径约 $2\Delta x$ 的局部邻域, 足以捕捉等值面穿越方向的局部变化。选择两层而非更深的网络是为了避免过度平滑 (over-smoothing), 保持不同位置顶点表示的区分度。

排列不变读出。 图级表示需要从变长的顶点表示集合 $\{h_p^{(2)}\}_{p \in V_{\text{act}}}$ 中得到固定长度向量。本文采用双池化 + 规模编码的读出策略:

$$z_\ell(v) = \text{L2Norm}[\text{MeanPool}(H^{(2)}) \parallel \text{MaxPool}(H^{(2)}) \parallel \log(1+|V_{\text{act}}|) \parallel \log(1+|E_{\text{act}}|)], \quad (12)$$

其中 $\parallel$ 表示向量拼接。均值池化捕捉顶点表示的"平均水平" (反映全局结构趋势), 最大值池化捕捉"极端信号" (反映局部最显著的结构特征); 两个对数规模项 $\log(1+|V_{\text{act}}|)$ 和 $\log(1+|E_{\text{act}}|)$ 显式编码活性子图的规模——由于池化操作丢失了节点数量信息, 规模项弥补这一缺失, 使得大规模等值面与小规模等值面即使结构相似也能在向量空间中区分。最终经 L_2 归一化映射到单位超球面上, 得到 $z_\ell(v) \in \mathbb{R}^{2h+2}$ (h 为隐藏维度)。

固定权重策略。 本文默认采用确定性固定权重 (He 初始化), 无需标注数据和训练过程。这一选择基于以下考量: (1) 本文目标是度量"相对差异"而非"绝对语义"——只需 GNN 对不同结构产生不同的向量即可, 不要求向量空间具有特定语义对齐; (2) 随机特征映射的理论保证——对足够宽的随机网络 (hidden dimension 足够大), 不同输入以高概率映射到不同向量, 满足差异度量的需求; [30] (3) 免训练使方法无需额外数据集、无需调参, 可直接应用于任意标量场数据。

差异计算。 参考节点与候选节点的分支差异由余弦距离给出:

$$d_\ell(v_r, v_i) = 1 - \cos(z_\ell(v_r), z_\ell(v_i)). \quad (13)$$

由于 z_ℓ 已经 L_2 归一化, 余弦距离等价于向量端点在单位超球面上的弦距离的单调变换。 $d_\ell = 0$ 意味着两个活性子图的 GNN 编码完全对齐 (结构高度相似), $d_\ell = 2$ 为理论最大值 (方向完全相反)。与 Jaccard 相比, 向量化方法对轻微平移和少量边增删更鲁棒——因为消息传递机制使相邻顶点的表示平滑化, 少量边的增删仅引起向量的微小扰动而非 Jaccard 中的离散跳变。两种度量互为对照, 从"显式边集"到"向量化结构"两个粒度刻画分支差异, 用户可根据对可解释性和鲁棒性的侧重选择。

3.4 基于多分支加权的贪心简化算法

基于前述多分支权重 (3.1 节)、亏格不变约束 (3.2 节) 和分支几何差异 (3.3 节), 本节给出完整的贪心简化算法。

给定增广轮廓树 $T = (V, E, f)$ 和容差 $\varepsilon > 0$, 目标是寻找保留集合 $K \subseteq V$, 使 $V_s \subseteq K$ (结构节点全部保留), 且在每条分支 $b = (v_0, \dots, v_k)$ 内, 相邻保留节点之间的多分支加权差异满足 $D(u_{j-1}, u_j) < \varepsilon$ 。算法对每条分支独立执行链上贪心: 保留起点 v_0 并令 $v_r \leftarrow v_0$, 依次扫描中间候选节点 v_i , 计算活跃分支集合 $\mathcal{B}(t_i)$ 上的加权差异 $D(v_r, v_i)$ (式 (6)); 若 $D \geq \varepsilon$ 则保留 v_i 并更新参考节点, 否则跳过; 扫描结束后始终保留终点 v_k 。

Algorithm 1 基于多分支加权的贪心简化

Require: 增广轮廓树 $T = (V, E, f)$, 容差 ε , 混合系数 α

Ensure: 保留节点集合 K , 几何过滤增广轮廓树 T'

```

1: 识别结构节点  $V_s$ , 分解拓扑分支  $\{b_1, \dots, b_n\}$ 
2:  $K \leftarrow V_s$ 
3: for all 拓扑分支  $b = (v_0, \dots, v_k)$  do
4:    $v_r \leftarrow v_0$ 
5:   for  $i \leftarrow 1$  to  $k - 1$  do
6:      $t_i \leftarrow f(v_i)$ 
7:      $\mathcal{B}(t_i) \leftarrow$  式 (3) 确定的活跃分支集合
8:     for all  $b_\ell \in \mathcal{B}(t_i)$  do
9:        $d_\ell \leftarrow \text{BRANCHDIFF}(v_r, v_i, b_\ell) \triangleright$  式 (10) 或 (13)
10:      由式 (4)、(5) 计算  $w_\ell$ 
11:     end for
12:      $D \leftarrow \sum_\ell w_\ell d_\ell$ 
13:     if  $D \geq \varepsilon$  then
14:        $K \leftarrow K \cup \{v_i\}$ ;  $v_r \leftarrow v_i$ 
15:     end if
16:   end for
17: end for
18: 合并被删节点跨越的弧, 重建  $T'$ 
19: return  $K, T'$ 

```

全部分支完成保留判定后, 合并被删节点跨越的弧 (新弧标量跨度取两端保留节点之差、区域规模取被合并各弧之和), 重建得到的 T' 保持原树根、叶和分支节点结构, 是一棵合法的几何过滤增广轮廓树。

复杂度。 结构节点识别与分支分解为 $O(|V|)$ 。链上贪心对每个候选节点各处理一次, 在至多 q 个活跃分支上计算差异, 总代价为 $O(|V_o| q C(\bar{s}))$, 其中 $C(\bar{s})$ 为单分支差异代价: Jaccard 为 $O(\bar{s})$ (边集交并), GNN 为 $O(\bar{s} h)$ (两层前向传播), $\bar{s}$ 为平均活性边数、 h 为隐藏维度。参考节点描述符可缓存, 避免重复计算。

参考文献

- [1] W. E. Lorensen and H. E. Cline. Marching cubes: A high resolution 3D surface construction algorithm. *Computer Graphics*, 21(4):163–169, 1987.
- [2] H. Edelsbrunner and J. L. Harer. *Computational Topology: An Introduction*. American Mathematical Society, 2010.
- [3] J. Milnor. *Morse Theory*. Princeton University Press, 1963.
- [4] X. Ni, M. Garland, and J. C. Hart. Fair Morse functions for extracting the topological structure of a surface mesh. *ACM Transactions on Graphics*, 23(3):613–622, 2004.
- [5] M. van Kreveld, R. van Oostrum, C. Bajaj, V. Pascucci, and D. Schikore. Contour trees and small seed sets for isosurface traversal. *Proceedings of the 13th Annual Symposium on Computational Geometry*, pages 212–220, 1997.
- [6] H. Carr, J. Snoeyink, and U. Axen. Computing contour trees in all dimensions. *Computational Geometry*, 24(2):75–94, 2003.
- [7] H. Edelsbrunner, D. Letscher, and A. Zomorodian. Topological persistence and simplification. *Discrete & Computational Geometry*, 28(4):511–533, 2002.
- [8] H. Carr, J. Snoeyink, and M. van de Panne. Simplifying flexible isosurfaces using local geometric measures. *IEEE Visualization*, pages 497–504, 2004.
- [9] H. Carr, J. Snoeyink, and M. van de Panne. Flexible isosurfaces: Simplifying and displaying scalar topology using the contour tree. *Computational Geometry*, 43(1):42–58, 2010.
- [10] C. Gueunet, P. Fortin, J. Jomier, and J. Tierny. Task-based augmented contour trees with Fibonacci heaps. *IEEE Transactions on Parallel and Distributed Systems*, 30(8):1889–1905, 2019.
- [11] J. Lukasczyk, M. Will, F. Wetzels, G. H. Weber, and C. Garth. ExTreeM: Scalable augmented merge tree computation via extremum graphs. *IEEE Transactions on Visualization and Computer Graphics*, 2023.
- [12] J. Tierny, G. Favelier, J. A. Levine, C. Gueunet, and M. Michaux. The Topology ToolKit. *IEEE Transactions on Visualization and Computer Graphics*, 24(1):832–842, 2018.
- [13] M. Li, H. Carr, O. Rübel, B. Wang, and G. H. Weber. Distributed augmentation, hypersweeps, and branch decomposition of contour trees for scientific exploration. *IEEE Transactions on Visualization and Computer Graphics*, 2024.
- [14] M. Li, H. Carr, O. Rübel, B. Wang, and G. H. Weber. Extremely scalable distributed computation of contour trees via pre-simplification. *IEEE Symposium on Large Data Analysis and Visualization (LDAV)*, 2025.
- [15] R. Sridharamurthy and V. Natarajan. Comparative analysis of merge trees using local tree edit distance. *IEEE Transactions on Visualization and Computer Graphics*, 29(2):1518–1530, 2023.
- [16] F. Wetzels, M. Pont, J. Tierny, and C. Garth. Merge tree geodesics and barycenters with path mappings. *IEEE Transactions on Visualization and Computer Graphics*, 2023.
- [17] M. Pont and C. Garth. Region-aware Wasserstein distances of persistence diagrams and merge trees. *IEEE Transactions on Visualization and Computer Graphics*, 2025.
- [18] C. L. Bajaj, V. Pascucci, and D. R. Schikore. The contour spectrum. *IEEE Visualization*, pages 167–174, 1997.
- [19] Y.-J. Chiang and X. Lu. Progressive simplification of tetrahedral meshes preserving all isosurface topologies. *Computer Graphics Forum*, 22(3):493–504, 2003.
- [20] S. Bruckner and T. Möller. Isosurface similarity maps. *Computer Graphics Forum*, 29(3):773–782, 2010.
- [21] Z. Wang. Representative isovalue detection and isosurface segmentation using novel isosurface measures. *Computer Graphics Forum*, 39(3):37–47, 2020.
- [22] H. Dai, Y. Tao, X. He, and H. Lin. IsoExplorer: An isosurface-driven framework for 3D shape analysis of biomedical volume data. *Journal of Visualization*, 2021.

- [23] X. He, Y. Tao, S. Yang, C. Chen, and H. Lin. ScalarGCN: Scalar-value association analysis of volumes based on graph convolutional network. *Journal of Visualization*, 2021.
- [24] H. Li and H.-W. Shen. Improving efficiency of iso-surface extraction on implicit neural representations using uncertainty propagation. *IEEE Transactions on Visualization and Computer Graphics*, 2024.
- [25] P. Li, C. Chen, F. Wang, X. Zhang, and Y. Wang. Multi-view isosurface similarity analysis for transfer function design in direct volume rendering. *Computers & Graphics*, 2025.
- [26] F. Zhou, H. Hu, F. Wang, J. Zhu, and W. Gao. Key-isovalue selection and hierarchical exploration visualization of weather forecast ensembles. *Visual Informatics*, 2025.
- [27] T. N. Kipf and M. Welling. Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations*, 2017.
- [28] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. *Advances in Neural Information Processing Systems*, 30, 2017.
- [29] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, and G. E. Dahl. Neural message passing for quantum chemistry. *International Conference on Machine Learning*, pages 1263–1272, 2017.
- [30] K. Xu, W. Hu, J. Leskovec, and S. Jegelka. How powerful are graph neural networks? *International Conference on Learning Representations*, 2019.
- [31] L. Rampasek, M. Galkin, V. P. Dwivedi, A. T. Luu, G. Wolf, and D. Beaini. Recipe for a general, powerful, scalable graph transformer. *Advances in Neural Information Processing Systems*, 35, 2022.
- [32] G. Bar-Shalom, B. Bevilacqua, and H. Maron. Subgraphormer: Unifying subgraph GNNs and graph transformers via graph products. *International Conference on Machine Learning*, 2024.
- [33] R. Hanocka, A. Hertz, N. Fish, R. Giryes, S. Fleishman, and D. Cohen-Or. MeshCNN: A network with an edge. *ACM Transactions on Graphics*, 38(4):90:1–90:12, 2019.
- [34] N. Sharp, S. Attaiki, K. Crane, and M. Ovsjanikov. DiffusionNet: Discretization agnostic learning on surfaces. *ACM Transactions on Graphics*, 41(3):27:1–27:16, 2022.
- [35] T. Pfaff, M. Fortunato, A. Sanchez-Gonzalez, and P. W. Battaglia. Learning mesh-based simulation with graph networks. *International Conference on Learning Representations*, 2021.
- [36] M. A. Nabian, C. Liu, R. Ranade, and S. Choudhry. X-MeshGraphNet: Scalable multi-scale graph neural networks for physics simulation. *arXiv preprint arXiv:2411.17164*, 2024.
- [37] E. Jain, I. Roy, S. Meher, S. Chakrabarti, and A. De. Graph edit distance with general costs using neural set divergence. *Advances in Neural Information Processing Systems*, 37, 2024.
- [38] Y. Qin, B. T. Fasy, C. Wenk, and B. Summa. Rapid and precise topological comparison with merge tree neural networks. *IEEE Transactions on Visualization and Computer Graphics*, 2024.