

基于图神经网络的几何过滤增广轮廓树

Geometric Filtered Augmented Contour Tree Using Graph Neural Network

2 相关研究与研究动机

本节按“背景—研究动机—相关研究”的顺序展开：2.1 节给出等值面、轮廓树及其亏格、欧拉示性数与连通性的学术化背景；2.2 节从“选择代表性等值面”出发引出本文方法；2.3 节梳理已有的拓扑与几何两类工作。

2.1 背景

等值面 科学计算、医学影像和流体模拟中的数据常表示为定义在空间域上的标量场 $f: \Omega \rightarrow \mathbb{R}$ 。给定标量阈值 α ，其等值面 (isosurface) 定义为原像 $f^{-1}(\alpha) = \{x \in \Omega \mid f(x) = \alpha\}$ ，在三维标量场中一般是一张或多张独立的封闭曲面。Marching Cubes 等方法可在规则网格上把 $f^{-1}(\alpha)$ 显式重建为三角网格 (triangle mesh)，是流场可视化分析中刻画结构的基本工具。[1] 然而逐阈值抽取只能给出孤立层级的几何，难以揭示等值面随阈值连续变化时的全局层次结构。

轮廓树 拓扑数据分析为此提供了更紧凑的表示。轮廓树 (contour tree) 通过刻画等值面连通分量随阈值变化的演化，把连续阈值空间压缩为一棵树：它记录等值面 $f^{-1}(\alpha)$ 的连通分量随阈值 α 变化而出生、合并、分裂与消亡的过程。[5, 6] 形式上，它可由记录子水平集 $F_\alpha = \{x \in \Omega \mid f(x) \leq \alpha\}$ 连通分量演化的并树 (join tree) 与记录超水平集演化的分裂树 (split tree) 合并得到。极值点、鞍点和分支节点对应关键拓扑事件，树边则表示相邻事件之间的演化区间。Topology ToolKit (TTK) 等工具已将这些结构封装为可与 ParaView、VTK 衔接的工程模块，为轮廓树的计算与增广提供了标准实现。[12]

等值面的亏格与欧拉示性数 等值面的亏格 (genus) g 在拓扑学上的直观含义是一张闭合、可定向曲面上所含“把手” (handles) 或“孔洞” (holes) 的数量，是刻画其复杂程度的核心拓扑不变量： $g = 0$ 对应球面， $g = 1$ 对应环面（如甜甜圈或带一个把手的杯子）， $g = 2$ 对应双环面， $g = n$ 则对应带 n 个相互独立把手的曲面。亏格亦可由 Betti 数刻画——对一张连通闭合可定向曲面，0 维 Betti 数 $\beta_0 = 1$ 计连通分量、1 维 Betti 数满足 $\beta_1 = 2g$ 、2 维 Betti 数

$\beta_2 = 1$ ——从而把“把手数”与曲面上独立环路的数量联系起来。[2] 对由 Marching Cubes 抽取的三角网格，亏格通过网格的点、边、面数量联合定义。对一个连通且闭合的等值面网格，其欧拉示性数 (Euler characteristic) 为

$$\chi = V - E + F, \quad (1)$$

其中 V, E, F 分别为顶点、边、三角面片总数。由拓扑学定理，欧拉示性数与亏格满足线性关系

$$\chi = 2 - 2g, \quad g = \frac{2 - \chi}{2}. \quad (2)$$

若同一阈值下抽取出 c 个彼此不相连的独立封闭曲面（各自亏格之和为 g ），则关系修正为 $\chi = 2c - 2g$ ，即 $g = (2c - \chi)/2$ 。因此，只要能沿阈值追踪 χ 的变化，就能反推等值面的亏格演化。

轮廓树与等值面亏格的关系 轮廓树本身无法完全表达等值面的亏格——它记录连通分量的演化，却不直接给出每张曲面上“把手”的数量，两个亏格截然不同的等值面在轮廓树上可能共享完全相同的边。[9] 但亏格的变化严格遵循 Morse 理论：[3, 2] 只有当阈值 h 穿过轮廓树的节点（临界点）时等值面的拓扑才会跳变，且每个临界点对欧拉示性数的贡献由其 Morse 指数 i 决定——指数 i 的临界点使 χ 改变 $(-1)^i$ 。在三维标量场中， $i = 0$ （极小值）与 $i = 3$ （极大值）对应等值面连通分量的出生与消亡， $i = 1$ 与 $i = 2$ 的鞍点则对应亏格的改变：当等值面在两处相交、在中间形成一条通道（环）时亏格加一，对应一阶鞍点 (1-saddle)；当通道闭合时亏格减一，对应二阶鞍点 (2-saddle)。据此，已有工作可在轮廓树的极小值边上初始化 χ ，沿阈值扫描在每个节点按其类型累加贡献，从而在保留树结构的同时把亏格信息补全到树的每条边上；实际数据中常出现的多重（非 Morse）鞍点需先经虚拟扰动拆解为标准一阶、二阶鞍点组合，才能保证贡献累加正确。[5, 6, 4] 本文不显式计算亏格，仅将上述关系作为说明等值面代表性、并论证“树边内部拓扑不变”的理论背景。

轮廓树与等值面连通性的关系 若说亏格描述单张曲面的复杂程度，连通性则描述等值面在阈值扫描中的整体演变，而轮廓树正是这一演变的“家谱”：它追踪并记录等值面在不同阈值下的连通分量如何诞生、合并、分裂与消失。轮廓

表 1: 三维标量场中各类临界点 (Morse 指数 i) 对等值面欧拉示性数 χ 的贡献 $\Delta\chi = (-1)^i$ 。连通分量数 c 与亏格 g 的净变化再由 $\chi = 2c - 2g$ 统一反推——同一 $\Delta\chi$ 可能来自连通性事件或亏格事件, 需结合分量数区分。

类型	$\Delta\chi$	主要拓扑含义
极小值 ($i = 0$)	+1	连通分量出生 (c 增)
一阶鞍点 ($i = 1$)	-1	连通分量合并, 或生成通道使 g 增
二阶鞍点 ($i = 2$)	+1	连通分量分裂, 或通道闭合使 g 减
极大值 ($i = 3$)	-1	连通分量消亡 (c 减)

树的节点恰是连通性发生改变的临界时刻——阈值经过极小值点时诞生一个新的连通分量, 经过极大值点时一个连通分量收缩为点而消失; 鞍点则是连通分量重组之处: 一个分量被“扯断”为两个 (分裂), 或两个原本独立的分量“黏连”为一个 (合并)。这一背景表明, 等值面的连通性与亏格变化都被编码在轮廓树的结构节点 (极值点与鞍点) 上, 而树边内部则是拓扑不变的演化区间。

2.2 研究动机

等值面是流场可视化分析中的重要工具, 选择有代表性的等值面对于刻画流场特征具有重要意义。一张等值面是否具有代表性, 可从三个方面衡量。其一是等值面的位置与分布: 代表性的等值面应覆盖标量场中不同的空间区域与阈值层级, 避免集中于单一区间而遗漏其他特征区域。其二是等值面的连通性以及亏格变化: 如 2.1 节所述, 连通分量的出生、合并、分裂、消亡以及亏格的增减都被编码在轮廓树的极值点与鞍点上, 代表性的等值面序列应完整覆盖这些拓扑事件。其三是等值面的几何特征: 即便拓扑不变, 等值面的形状、规模与截穿的局部结构仍可能明显演化, 代表性应捕捉这类几何差异。前两个方面主要与拓扑分析和简化相关, 其代表工作是轮廓树、合并树以及 Carr 等的柔性等值面框架; [6, 9, 11] 第三个方面主要与 ISM 等几何方法相关。[20] 然而如 2.3 节所述, 拓扑方法能保住连通性与亏格变化点却难以刻画分支内几何演化, 几何方法能度量形状差异却常脱离轮廓树分支、混合多分支变化, 现有研究因而并不能真正选出有代表性的等值面, 也没有方法同时针对上述三个方面。

本文正是为弥合这一空缺而提出。我们把“选择代表性等值面”具体化为增广轮廓树上的节点筛选问题: 为在连续阈值上保留代表性的等值状态, 增广轮廓树在临界节点之间插入大量普通节点, [11, 10, 14] 但相邻普通节点对应的等值结构往往高度相似, 造成冗余——保留全部普通节点会产生近似重复的等值面并增加存储与交互成本, 而不加区分地删除又会丢失真实的几何演化。本文在严格保留关键拓扑结构 (根、叶、鞍点与分支节点, 即连通性与亏格变化的临界点, 见 2.1 节) 的前提下, 沿拓扑分支筛选出

几何上有代表性的普通节点, 从而在位置分布、连通性与亏格、几何特征三个层面同时逼近原始等值面序列。

这一目标落实为三项设计。其一, 简化范围受拓扑约束: 结构节点全部保留, 候选普通节点沿所属拓扑分支顺序筛选, 简化后通过合并原始弧重建合法树, 从而保住连通性与亏格变化所依附的结构节点。其二, 基础差异度量按分支实例化: 本文统一以原始网格上的局部活性子图刻画分支局部结构, 并给出两种可替换的比较方式——活性边集合的 Jaccard 距离与活性子图的 GNN 向量化距离, 分别从显式边集与向量化结构两个角度度量几何差异。其三, 多分支场景下按重要性加权: 一个标量层级可能同时穿过主分支与旁支, 本文保留这些分支身份, 并按标量跨度型拓扑显著性与几何规模把多个分支的差异汇总为整体差异。据此, 本文提出一个拓扑保持的多分支感知增广轮廓树节点简化框架。

2.3 相关研究

围绕等值面表示与轮廓树简化的已有工作可从三个方面梳理: 拓扑驱动的合并树与轮廓树简化方法、几何驱动的等值面相似性度量方法, 以及面向网格数据的图表示学习方法。

Van Kreveld 等最早将轮廓树引入等值面遍历, 以其变体构造可证明规模最小的种子集从连通分量中精确提取等值面。[5] Carr 等提出通过合并 Join 树与 Split 树的通用维度轮廓树算法, 成为轮廓树计算的标准参考实现。[6] Edelsbrunner 等引入持久同调, 以特征在过滤中的存活时间区分信号与噪声, 奠定多尺度拓扑简化的理论基础。[7] Carr 等为轮廓树分支引入面积、体积以及兼顾空间规模与函数值偏离的超体积等局部几何度量, 作为分支剪枝的代价函数。[8] 在此基础上, Carr 等提出柔性等值面框架, 以轮廓树超级弧索引独立 contour, 并结合叶子剪枝与顶点归约实现交互式简化与显示, 是本文最直接的相关工作。[9] 面向并行计算, Gueunet 等提出值域分割的多线程轮廓森林算法, 首次实现共享内存并行的增广轮廓树计算; [10] 其后又提出基于 Fibonacci 堆的任务并行增广轮廓树算法, 是本文简化工作的直接操作对象。[11] Tierny 等开发 Topology ToolKit (TTK), 为合并树、轮廓树、Morse-Smale 复形等拓扑结构提供开源标准实现。[12] Lukasczyk 等提出局部化拓扑简化, 仅在含未选极值的子体上并行展平, 显著提升交互式参数探索的响应速度。[13] Li 等进一步将增广、超扫描与分支分解扩展到分布式环境, 使分布式轮廓树可作为科学探索的查询结构。[14]

Bajaj 等提出等值面谱 (contour spectrum), 将等值面面积、体积、梯度积分等属性表达为等值的分段 B 样条函数, 首次将几何量化方法引入等值面阈值选择。[15] Fujishiro 等以标量场临界点分析驱动体绘制传递函数自动

设计,是拓扑驱动传递函数路线的开创性工作。[16] Chiang 与 Lu 提出保持所有可能等值面拓扑的渐进四面体网格简化算法,是拓扑感知网格简化的关键先驱。[17] Takahashi 等提取体骨架树 (VST),以包含层级与轨道距离等拓扑属性自动设计多维传递函数。[18] Weber 等基于轮廓树分支分解将体数据分割为拓扑一致的区域,为每个分支独立指派传递函数,实现拓扑感知的选择性体绘制。[19] Bruckner 与 Möller 提出等值面相似性图 (ISM),以归一化互信息比较不同阈值下的距离场结构,从相似度矩阵中选出代表性等值面,是等值面几何相似性度量的里程碑。[20] Fofonov 与 Linsen 利用准蒙特卡洛采样近似距离场分布,显著降低 ISM 的计算代价。[21] Fernandes 等以最小费用流与 Hausdorff 距离的插值方法选取代表性等值面,可捕捉拓扑不变时仍存在的几何形变。[22] Tao 等将 ISM 扩展为矩阵形式,同时组织自、时间、变量三类相似图,支持时变多变量体数据的跨变量与跨时间步比较。[23] Wang 提出基于区间体与等值面面积的 VOA 度量以及基于点距的分割度量,用于自动检测代表性等值与语义化等值面分割。[24]

Kipf 与 Welling 提出图卷积网络 (GCN),通过对称归一化的一阶邻域聚合实现高效的半监督节点分类,是图神经网络最具影响力的基石模型。[25] Hamilton 等提出 GraphSAGE,以邻域采样与可学习聚合器实现大规模图上的归纳式表示学习,可为新节点生成 embedding。[26] Gilmer 等提出消息传递神经网络 (MPNN) 通用框架,将多种 GNN 变体统一到消息、更新与读出三阶段范式下。[27] Qi 等提出 PointNet,以对称最大池化直接在无序点上学习置换不变特征,其处理无序集合的思路对网格学习具有重要启示。[28] Battaglia 等系统综述图网络中的关系归纳偏置,提出统一的图网络 (GN) 框架并将 CNN、RNN 归为其特例。[29] Verma 等提出 FeaStNet,从学习到的特征动态计算滤波权重与图邻域的软对应关系,用于三维形状分析。[30] Hanocka 等提出 MeshCNN,在三角网格的边上定义卷积与池化操作,以任务驱动的边折叠在保持拓扑的同时实现网格分辨率降低。[31] Xu 等从理论上刻画消息传递 GNN 的判别能力上界,提出可达 Weisfeiler-Leman 测试上界的图同构网络 (GIN)。[32] Pfaff 等提出 MeshGraphNet,以编码-处理-解码架构在非结构化网格上直接学习物理模拟,是网格 GNN 物理建模的标准范式。[33] Sharp 等提出 DiffusionNet,以基于 Laplace-Beltrami 算子的学习扩散层实现对分辨率与采样变化自动鲁棒的表面学习,可跨 mesh 与点云表示。[34]

综上,拓扑方法能保住连通性与亏格变化点却难以刻画分支内几何演化,几何方法能度量形状差异却脱离轮廓树分支结构,图表示学习提供了局部结构编码的工具但尚未应用于等值面代表性筛选。三者尚未在同一框架内统一,这一空缺正是本文工作的出发点。

3 方法

本节给出基于几何过滤的增广轮廓树节点简化方法。输入为定义在规则网格 Ω 上的标量场 $f: \Omega \rightarrow \mathbb{R}$ 及其增广轮廓树 $T = (V, E, f)$, 输出为几何过滤增广轮廓树 T' ——在严格保留连通性与亏格变化临界点的前提下,沿拓扑分支筛选出几何上有代表性的普通节点后重建而得的简化树。全文按以下逻辑展开: 3.1 节定义拓扑分支并给出多分支权重设计; 3.2 节说明亏格不变区间的划分与分支映射; 3.3 节在每条分支上定义局部活性子图并给出两种几何表示学习方法 (Jaccard 距离与 GNN 向量化距离); 3.4 节将前述组件统一为多分支感知的贪心简化算法。

3.1 拓扑分支分解与多分支权重

拓扑分支。 增广轮廓树的节点按拓扑角色分为两类: 结构节点集合 V_s (根节点、叶节点/极值点和分支节点/鞍点) 记录连通性和亏格的变化; 普通节点集合 $V_o = V \setminus V_s$ (度数为 2、不改变连通性的增广节点) 记录中间等值面状态。从每个结构节点出发,沿度数为 2 的普通节点连续游走直到到达下一个结构节点,即得一条**拓扑分支** (topological branch)

$$b = (v_0, v_1, \dots, v_k), \quad (3)$$

其中 v_0, v_k 为必须保留的结构节点,中间节点按标量值排序定向,全为候选普通节点。整棵增广轮廓树被这些拓扑分支无重叠地分解。

分支的标量跨度型拓扑显著性。 每条拓扑分支 b_ℓ 的标量范围记为 $[f_{\min}(b_\ell), f_{\max}(b_\ell)]$, 其标量跨度定义为

$$\pi_\ell = f_{\max}(b_\ell) - f_{\min}(b_\ell), \quad (4)$$

可视为持久性思想在本文拓扑分支定义下的工程近似: π_ℓ 越大,该分支承载的标量演化范围越宽,在全局结构中越显著。

活跃分支集合。 在轮廓树中,同一标量层级可能同时穿过多条拓扑分支。对候选节点 v_i (阈值 $t_i = f(v_i)$), 其活跃分支集合定义为

$$\mathcal{B}(t_i) = \{b_\ell \mid f_{\min}(b_\ell) \leq t_i \leq f_{\max}(b_\ell)\}. \quad (5)$$

这些分支共同构成该层级上等值面的完整拓扑与几何背景,节点筛选判定应同时考虑所有活跃分支的变化。

拓扑权重。 对活跃分支集合 $\mathcal{B}(t_i)$ 中的每条分支 b_ℓ , 其拓扑权重定义为

$$w_\ell^{\text{topo}} = \frac{\pi_\ell}{\sum_{k: b_k \in \mathcal{B}(t_i)} \pi_k}, \quad (6)$$

使标量跨度较大的主分支获得更高权重，体现其在全局拓扑结构中的重要性。

几何规模权重。 除拓扑显著性外，分支在当前层级的局部几何规模也应影响权重。记分支 b_ℓ 在候选节点 v_i 处的局部活性子图规模（活性边数，见 3.3 节）为 s_ℓ ，则几何规模权重为

$$w_\ell^{\text{geo}} = \frac{s_\ell}{\sum_{k: b_k \in \mathcal{B}(t_i)} s_k}, \quad (7)$$

使局部结构规模大的分支获得更高权重。

混合权重。 二者通过混合系数 $\alpha \in [0, 1]$ 线性组合并归一化为最终权重

$$w_\ell = \frac{\alpha w_\ell^{\text{topo}} + (1 - \alpha) w_\ell^{\text{geo}}}{\sum_k [\alpha w_k^{\text{topo}} + (1 - \alpha) w_k^{\text{geo}}]}. \quad (8)$$

$\alpha = 1$ 退化为纯拓扑权重， $\alpha = 0$ 退化为纯几何规模权重。纯拓扑权重倾向于保护标量跨度大的主分支，但可能低估跨度不大却正经历明显截交变化的旁支；纯几何规模权重响应局部结构规模，却可能让大分支持续主导而稀释小而拓扑重要的分支。通过 α 混合可在二者之间取得折中。各活跃分支的局部差异 d_ℓ （定义见 3.3 节）经 w_ℓ 加权汇总为整体差异

$$D(v_r, v_i) = \sum_{\ell: b_\ell \in \mathcal{B}(t_i)} w_\ell d_\ell(v_r, v_i), \quad \sum_\ell w_\ell = 1, \quad (9)$$

其中 v_r 为最近一次保留的参考节点。 D 是贪心简化（3.4 节）的核心判据。

3.2 亏格不变区间与分支映射

亏格不变区间。 如 2.1 节所述，Morse 理论保证：只有当阈值穿过轮廓树的临界点（结构节点）时等值面的拓扑才会跳变，每个临界点对欧拉示性数的贡献为 $\Delta\chi = (-1)^i$ （ i 为 Morse 指数）。由此可知，在两个相邻结构节点之间的标量区间内，等值面的连通分量数和亏格均保持不变——这正是拓扑分支内部“拓扑不变”的理论根据。

形式上，设拓扑分支 $b_\ell = (v_0, \dots, v_k)$ 的端点 v_0, v_k 为结构节点，则标量区间 $(f(v_0), f(v_k))$ 内不存在其他临界点，该区间即为一个**亏格不变区间**（genus-invariant interval）。在此区间内，等值面的拓扑类型（连通分量数 c 和亏格 g ）不随阈值变化，只有几何形状可能演化。

分支与亏格不变区间的映射。 每条拓扑分支 b_ℓ 自然对应一个亏格不变区间 $I_\ell = (f(v_0), f(v_k))$ 。这一映射具有以下关键性质：

(1) **分支内部拓扑不变：** 对 b_ℓ 上的任意两个普通节点 v_i, v_j ，其对应的等值面具有相同的连通分量数和亏格。因

此，两者之间的差异纯粹是几何差异，可用几何度量（3.3 节）来刻画。

(2) **亏格变化仅发生在端点：** 等值面的亏格跳变编码在分支端点（结构节点）上，包括一阶鞍点（ $i = 1$ ，使 g 增加）和二阶鞍点（ $i = 2$ ，使 g 减少）。本文通过保留所有结构节点来保证亏格变化点不被删除。

(3) **连通分支感知：** 同一标量层级 t_i 可能穿过多条拓扑分支（式 (5)），每条分支对应一个独立的亏格不变区间。本文通过分支局部化（3.3 节）确保几何比较被限制在各自的亏格不变区间内，避免跨分支混合。

这一结构保证了本文方法的理论正确性：结构节点全部保留确保不丢失任何亏格变化事件；分支内部仅做几何筛选，不会引入或遗漏拓朴事件；多分支加权（3.1 节）保持各分支的独立性，不跨越亏格不变区间进行混合比较。

3.3 分支上的几何表示学习

由 3.2 节可知，拓扑分支内部等值面的差异纯粹是几何差异。本节定义统一的局部结构描述子——活性子图，并给出两种可替换的几何差异度量：活性边集合的 Jaccard 距离与活性子图的 GNN 向量化距离。

3.3.1 局部活性子图

活性边与活性子图。 等值面 $\{x \mid f(x) = t\}$ 在规则网格上的离散痕迹，是那些被该等值面穿过的网格边。对原始网格边 (p, q) ，若其两端点标量值跨越阈值 $t = f(v)$ ：

$$f(p) \leq t < f(q) \quad \text{或} \quad f(q) \leq t < f(p), \quad (10)$$

则称该边为阈值 t 下的**活性边**。所有活性边及其端点构成**局部活性子图**

$$G_\ell(v) = (V_{\text{act}}(v), E_{\text{act}}(v)). \quad (11)$$

相比直接重建等值面三角网格，活性子图无需插值和三角化，天然保留原始网格的连通关系，把“等值面扫过了哪些局部结构”这一问题转化为对一组网格边的比较。

分支局部化。 为把比较限制在当前分支 b_ℓ 的亏格不变区间内、排除同一阈值下其他分支的无关活性边，遍历范围由 b_ℓ 关联弧的分割标签（SegmentationId）集合确定：仅在这些分割区域的联合包围盒内枚举网格边，并要求边的至少一个端点落在目标分割内。由此得到的 $G_\ell(v)$ 只反映 b_ℓ 上的等值面截交结构，保证了分支间互不干扰。

3.3.2 活性边集合的 Jaccard 差异

第一种几何差异度量直接比较两个节点活性边集合的重合程度。由于所有活性子图都嵌在同一母网络上、共享一致的网格边编号，边集重合程度具有明确含义：重合度

高说明等值面在该分支上扫过的局部结构基本未变；差异越大说明等值面已移动到新的网格区域。

记 $E_{\text{act}}(v_r)$ 、 $E_{\text{act}}(v_i)$ 为参考节点与候选节点在分支 b_ℓ 上的活性边集合，Jaccard 差异为

$$d_\ell^J = 1 - \frac{|E_{\text{act}}(v_r) \cap E_{\text{act}}(v_i)|}{|E_{\text{act}}(v_r) \cup E_{\text{act}}(v_i)|}. \quad (12)$$

然而纯边集 Jaccard 对等值面轻微平移较敏感。为缓解这一点，引入质心位移项与包围盒尺度变化项作为几何补偿。设活性子图顶点集 $V_{\text{act}}(v)$ 的质心为 $c(v)$ 、包围盒对角线长度为 $\text{diag}(v)$ ：

$$d_\ell^{\text{pos}} = \frac{\|c(v_r) - c(v_i)\|}{\max(\text{diag}(v_r), \epsilon_0)}, \quad (13)$$

$$d_\ell^{\text{bbox}} = \frac{|\text{diag}(v_r) - \text{diag}(v_i)|}{\max(\text{diag}(v_r), \epsilon_0)}, \quad (14)$$

其中 ϵ_0 为防除零小正数。三项取最大值合成该分支上的单分支差异

$$d_\ell(v_r, v_i) = \max(d_\ell^J, \lambda_p d_\ell^{\text{pos}}, \lambda_b d_\ell^{\text{bbox}}), \quad (15)$$

λ_p, λ_b 为两个补偿项的相对权重。取最大值而非求和，使得边集重组、整体平移或尺度膨胀中任一通道发生显著变化都足以触发保留。

3.3.3 局部活性子图的 GNN 向量化差异

边集 Jaccard 直接且可解释，但对网格离散化和轻微平移较敏感。第二种度量把同一活性子图编码成固定长度向量，在向量空间中比较结构相似性，将"边是否逐一重合"放松为"局部结构是否相似"。

节点特征。 对每个活性顶点 p ，构造 11 维特征向量 x_p ：第 1 维为全局归一化标量 $(f(p) - f_{\min})/(f_{\max} - f_{\min})$ ；第 2、3 维为相对阈值的有符号偏差 $(f(p) - t)$ 及其绝对值；第 4–6 维为顶点相对子图质心的坐标（按包围盒对角线归一化）；第 7 维为归一化顶点度数；第 8–11 维为分割标签的多尺度正余弦编码。这些特征对全局平移和尺度保持不变。

图编码。 以特征矩阵 $X \in \mathbb{R}^{|V_{\text{act}}| \times 11}$ 和活性子图邻接为输入，使用两层图卷积网络 (GCN) 做对称归一化邻域聚合：

$$H^{(1)} = \text{ReLU}(\hat{A} X W^{(1)}), \quad H^{(2)} = \text{ReLU}(\hat{A} H^{(1)} W^{(2)}), \quad (16)$$

其中 $\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ 为加自环后的对称归一化邻接矩阵， $W^{(1)} \in \mathbb{R}^{11 \times h}$ 、 $W^{(2)} \in \mathbb{R}^{h \times h}$ 为 GCN 权重， h 为隐藏维度。两层传播使每个顶点聚合其二跳邻域信息。随后

对 $H^{(2)}$ 做排列不变的读出，拼接均值池化与最大值池化，并附加两个对数规模项以保留子图大小信息：

$$z_\ell(v) = \text{normalize} \left[\text{mean}(H^{(2)}) \parallel \text{max}(H^{(2)}) \parallel \log(1+|V_{\text{act}}|) \parallel \log(1+|E_{\text{act}}|) \right], \quad (17)$$

最终经 L_2 归一化得到 $z_\ell(v) \in \mathbb{R}^{2h+2}$ 。本文默认采用确定性固定权重 (He 初始化，固定随机种子)，使方法无需标注数据即可运行。

分支差异。 参考节点与候选节点在分支 b_ℓ 上的差异由余弦距离给出：

$$d_\ell(v_r, v_i) = 1 - \cos(z_\ell(v_r), z_\ell(v_i)). \quad (18)$$

与 Jaccard 相比，向量化方法对轻微平移和少量边增删更鲁棒，但可解释性弱于显式边集比较。两种度量互为对照，依次从"显式边集"到"向量化结构"刻画分支差异。

3.4 多分支感知贪心简化算法

基于前述三节定义的多分支权重 (3.1 节)、亏格不变约束 (3.2 节) 和分支几何差异度量 (3.3 节)，本节给出完整的贪心简化算法。

问题定义。 给定增广轮廓树 $T = (V, E, f)$ 和容差 $\varepsilon > 0$ ，目标是寻找保留集合 $K \subseteq V$ 满足

$$V_s \subseteq K \subseteq V, \quad (19)$$

并且在每条拓扑分支 $b = (v_0, \dots, v_k)$ 内，把 $K \cap b$ 按标量排序为序列 $v_0 = u_0, u_1, \dots, u_m = v_k$ 时，相邻保留节点之间的多分支加权差异受阈值控制：

$$D(u_{j-1}, u_j) < \varepsilon, \quad j = 1, \dots, m. \quad (20)$$

链上贪心策略。 对每条拓扑分支 $b = (v_0, \dots, v_k)$ 独立执行。算法保留分支起点 v_0 并令 $v_r \leftarrow v_0$ ，随后依次扫描中间候选节点 v_i ：计算当前层级 $t_i = f(v_i)$ 的活跃分支集合 $\mathcal{B}(t_i)$ ，在每条活跃分支上分别计算 $d_\ell(v_r, v_i)$ 并按式 (9) 汇总为整体差异 $D(v_r, v_i)$ ；若

$$D(v_r, v_i) \geq \varepsilon, \quad (21)$$

则保留 v_i 并更新 $v_r \leftarrow v_i$ ，否则跳过；扫描结束后始终保留终点 v_k 。这一策略不依赖全局优化，线性、可控，适合在增广轮廓树的多条分支上独立执行。

简化树重建。 对全部分支完成保留节点判定后，根据保留集合 K 合并被删除节点跨越的弧：新弧的标量跨度取两端保留节点之差，区域规模取被合并各弧之和。重建得到

的简化树 T' 与原树保持相同的根、叶和分支节点结构，是一棵合法的几何过滤增广轮廓树。

Algorithm 1 多分支感知贪心简化（总体框架）

Require: 增广轮廓树 $T = (V, E, f)$, 容差 ε , 混合系数 α

Ensure: 保留节点集合 K , 几何过滤增广轮廓树 T'

```

1: 识别结构节点  $V_s$ , 分解拓扑分支  $\{b_1, \dots, b_n\}$ 
2:  $K \leftarrow V_s$ 
3: for all 拓扑分支  $b = (v_0, \dots, v_k)$  do
4:    $v_r \leftarrow v_0$ 
5:   for  $i \leftarrow 1$  to  $k - 1$  do
6:      $t_i \leftarrow f(v_i)$ 
7:      $\mathcal{B}(t_i) \leftarrow$  式 (5) 确定的活跃分支集合
8:     for all  $b_\ell \in \mathcal{B}(t_i)$  do
9:        $d_\ell \leftarrow \text{BRANCHDIFF}(v_r, v_i, b_\ell) \triangleright$  式 (15) 或
(18)
10:      由式 (6)、(7)、(8) 计算  $w_\ell$ 
11:     end for
12:      $D \leftarrow \sum_\ell w_\ell d_\ell$ 
13:     if  $D \geq \varepsilon$  then
14:        $K \leftarrow K \cup \{v_i\}; v_r \leftarrow v_i$ 
15:     end if
16:   end for
17: end for
18: 合并被删节点跨越的弧, 重建  $T'$ 
19: return  $K, T'$ 

```

复杂度分析。 设增广轮廓树总节点数为 $|V|$ 、候选普通节点总数为 $|V_o|$ 、单个标量层级的活跃分支数为 q (通常远小于分支总数)。结构节点识别与分支分解复杂度为 $O(|V|)$ 。链上贪心对每个候选节点各处理一次, 在至多 q 个活跃分支上计算分支差异, 总代价约为 $O(|V_o|qC(\bar{s}))$ 。其中 $C(\bar{s})$ 为单分支差异的计算代价: Jaccard 实例为 $O(\bar{s})$ (边集交并运算), GNN 实例为 $O(\bar{s}h)$ (两层 GCN 前向传播), $\bar{s} = |E_{\text{act}}|$ 为活性边数、 h 为隐藏维度。参考节点的局部描述符可缓存复用, 避免重复计算。

参考文献

- [1] W. E. Lorensen and H. E. Cline. Marching cubes: A high resolution 3D surface construction algorithm. *Computer Graphics*, 21(4):163–169, 1987.
- [2] H. Edelsbrunner and J. L. Harer. *Computational Topology: An Introduction*. American Mathematical Society, 2010.
- [3] J. Milnor. *Morse Theory*. Princeton University Press, 1963.
- [4] X. Ni, M. Garland, and J. C. Hart. Fair Morse functions for extracting the topological structure of a surface mesh. *ACM Transactions on Graphics*, 23(3):613–622, 2004.
- [5] M. van Kreveld, R. van Oostrum, C. Bajaj, V. Pascucci, and D. Schikore. Contour trees and small seed sets for isosurface traversal. *Proceedings of the 13th Annual Symposium on Computational Geometry*, pages 212–220, 1997.
- [6] H. Carr, J. Snoeyink, and U. Axen. Computing contour trees in all dimensions. *Computational Geometry*, 24(2):75–94, 2003.
- [7] H. Edelsbrunner, D. Letscher, and A. Zomorodian. Topological persistence and simplification. *Discrete & Computational Geometry*, 28(4):511–533, 2002.
- [8] H. Carr, J. Snoeyink, and M. van de Panne. Simplifying flexible isosurfaces using local geometric measures. *IEEE Visualization*, pages 497–504, 2004.
- [9] H. Carr, J. Snoeyink, and M. van de Panne. Flexible isosurfaces: Simplifying and displaying scalar topology using the contour tree. *Computational Geometry*, 43(1):42–58, 2010.
- [10] C. Gueunet, P. Fortin, J. Jomier, and J. Tierny. Contour forests: Fast multi-threaded augmented contour trees. *IEEE Symposium on Large Data Analysis and Visualization (LDAV)*, pages 85–92, 2016.
- [11] C. Gueunet, P. Fortin, J. Jomier, and J. Tierny. Task-based augmented contour trees with Fibonacci heaps. *IEEE Transactions on Parallel and Distributed Systems*, 30(8):1889–1905, 2019.
- [12] J. Tierny, G. Favelier, J. A. Levine, C. Gueunet, and M. Michaux. The Topology ToolKit. *IEEE Transactions on Visualization and Computer Graphics*, 24(1):832–842, 2018.
- [13] J. Lukasczyk, C. Garth, R. Maciejewski, and J. Tierny. Localized topological simplification of scalar data. *IEEE Transactions on Visualization and Computer Graphics*, 27(2):572–582, 2020.
- [14] M. Li, H. Carr, O. Rübel, B. Wang, and G. H. Weber. Distributed augmentation, hypersweeps, and branch decomposition of contour trees for scientific exploration. *IEEE Transactions on Visualization and Computer Graphics*, 2024.
- [15] C. L. Bajaj, V. Pascucci, and D. R. Schikore. The contour spectrum. *IEEE Visualization*, pages 167–174, 1997.
- [16] I. Fujishiro, T. Azuma, and Y. Takeshima. Automating transfer function design for comprehensible volume rendering based on 3D field topology analysis. *IEEE Visualization*, pages 467–470, 1999.
- [17] Y.-J. Chiang and X. Lu. Progressive simplification of tetrahedral meshes preserving all isosurface topologies. *Computer Graphics Forum*, 22(3):493–504, 2003.
- [18] S. Takahashi, Y. Takeshima, and I. Fujishiro. Topological volume skeletonization and its application to transfer function design. *Graphical Models*, 66(1):24–49, 2004.
- [19] G. H. Weber, S. E. Dillard, H. Carr, V. Pascucci, and B. Hamann. Topology-controlled volume rendering. *IEEE Transactions on Visualization and Computer Graphics*, 13(2):330–341, 2007.
- [20] S. Bruckner and T. Möller. Isosurface similarity maps. *Computer Graphics Forum*, 29(3):773–782, 2010.
- [21] A. Fofonov and L. Linsen. Fast and robust isosurface similarity maps extraction using quasi-Monte Carlo approach. *European Conference on Data Analysis (ECDA)*, 2014.
- [22] D. Fernandes, S. Frey, and T. Ertl. Interpolation-based extraction of representative isosurfaces. *International Symposium on Visual Computing (ISVC)*, LNCS, 2016.

- [23] J. Tao, E. Imre, C. Wang, N. V. Chawla, H. Guo, G. Sever, and S.-H. Kim. Exploring time-varying multivariate volume data using matrix of isosurface similarity maps. *IEEE Transactions on Visualization and Computer Graphics*, 25(1):1236–1245, 2019.
- [24] Z. Wang. Representative isovalue detection and isosurface segmentation using novel isosurface measures. *Computer Graphics Forum*, 39(3):37–47, 2020.
- [25] T. N. Kipf and M. Welling. Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations*, 2017.
- [26] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. *Advances in Neural Information Processing Systems*, 30, 2017.
- [27] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, and G. E. Dahl. Neural message passing for quantum chemistry. *International Conference on Machine Learning*, pages 1263–1272, 2017.
- [28] C. R. Qi, H. Su, K. Mo, and L. J. Guibas. PointNet: Deep learning on point sets for 3D classification and segmentation. *IEEE Conference on Computer Vision and Pattern Recognition*, pages 652–660, 2017.
- [29] P. W. Battaglia, J. B. Hamrick, V. Bapst, A. Sanchez-Gonzalez, et al. Relational inductive biases, deep learning, and graph networks. *arXiv preprint arXiv:1806.01261*, 2018.
- [30] N. Verma, E. Boyer, and J. Verbeek. FeaStNet: Feature-steered graph convolutions for 3D shape analysis. *IEEE Conference on Computer Vision and Pattern Recognition*, pages 2598–2606, 2018.
- [31] R. Hanocka, A. Hertz, N. Fish, R. Giryes, S. Fleishman, and D. Cohen-Or. MeshCNN: A network with an edge. *ACM Transactions on Graphics*, 38(4):90:1–90:12, 2019.
- [32] K. Xu, W. Hu, J. Leskovec, and S. Jegelka. How powerful are graph neural networks? *International Conference on Learning Representations*, 2019.
- [33] T. Pfaff, M. Fortunato, A. Sanchez-Gonzalez, and P. W. Battaglia. Learning mesh-based simulation with graph networks. *International Conference on Learning Representations*, 2021.
- [34] N. Sharp, S. Attaiki, K. Crane, and M. Ovsjanikov. DiffusionNet: Discretization agnostic learning on surfaces. *ACM Transactions on Graphics*, 41(3):27:1–27:16, 2022.